

Relatório do Projeto

Previsão da Qualidade do Ar em Lisboa

Ana Luiza de Lima Miranda Pinto

Portimão, 16 de Junho de 2025

1. Resumo	3
2. Introdução	3
3. Objetivos	4
4. Equipamento e software utilizados	4
5. Desenvolvimento	5
5.1 Coleta de dados	5
5.2 Análise de dados	5
5.3 Componentes da Série Temporal	5
5.4 Baseline com SARIMAX	6
5.5 Modelos de Machine Learning com Feature Engineering e Param Grid	6
5.6 Melhores modelos	6
5.7 Diferentes tipos de validações	6
6. Resultados	6
6.1 Análise da decomposição sazonal	6
6.2 Baseline com SARIMAX	6
6.3 Modelos de aprendizagem de máquina	7
6.4 Validação cruzada e testes expansivos	7
7. Discussão	7
8. Conclusão	8
9. Referências e Bibliografia	8

1. Resumo

Este projeto tem como objetivo o desenvolvimento de um sistema inteligente capaz de realizar previsões dos níveis de poluição do ar (material particulado - PM) a partir de séries temporais coletadas pela Agência Europeia do Meio Ambiente (EEA) entre 2018 e 2023, na cidade de Lisboa. Foram testados diferentes modelos de previsão, incluindo Regressão Linear, Random Forest, XGBoost e SARIMAX. O melhor desempenho foi obtido com o modelo de Regressão Linear, utilizando variáveis derivadas da própria série histórica, como defasagens (lags) e estatísticas móveis (média, mínimo, máximo e desvio padrão). Os melhores resultados foram obtidos utilizando a série transformada via $\log_{1p}$, com $MAE = 0.595$ e $RMSE = 0.826$ nos modelos de machine learning. Este desempenho foi superior tanto aos modelos treinados com a série original quanto ao baseline com SARIMAX puro. Além disso, foram realizadas diversas estratégias de validação cruzada específicas para séries temporais, garantindo a robustez e generalização do modelo final.

2. Introdução

O monitoramento da qualidade do ar é uma das principais preocupações ambientais atuais, dado o impacto direto que a poluição atmosférica tem sobre a saúde pública e o meio ambiente. A previsão dos níveis de poluentes como o material particulado (PM) é essencial para informar

políticas ambientais, alertar a população e otimizar medidas preventivas. Séries temporais são comumente utilizadas em contextos ambientais para prever concentrações futuras de poluentes. Organizações ambientais europeias e locais mantêm redes de sensores e coleta sistemática desses dados.

Tradicionalmente, métodos estatísticos como ARIMA e SARIMAX têm sido amplamente utilizados para previsão de séries temporais, principalmente em contextos econômicos, financeiros e ambientais. Esses modelos clássicos se destacam por sua capacidade de capturar padrões de autocorrelação e sazonalidade a partir da própria estrutura dos dados temporais, fornecendo parâmetros interpretáveis e permitindo modelagens específicas para séries estacionárias ou não estacionárias [1].

Por outro lado, algoritmos clássicos de aprendizado de máquina (ML) supervisionado, como Regressão Linear, Árvores de Decisão, Random Forest e XGBoost, não foram originalmente concebidos para lidar diretamente com dependências temporais. No entanto, ao se aplicar técnicas adequadas de engenharia de atributos — como a criação de variáveis defasadas (lags), janelas móveis e encoding temporal — esses algoritmos se tornam altamente competitivos na previsão de séries temporais [2].

Nos últimos anos, o campo também tem visto o surgimento de abordagens mais recentes e sofisticadas, como modelos baseados em redes neurais recorrentes (RNN), LSTMs e Transformers aplicados a séries temporais [3]. Embora esses modelos frequentemente obtenham desempenho superior em cenários mais complexos ou multivariados, eles exigem maior capacidade computacional, tuning cuidadoso e muitas vezes grandes volumes de dados.

Neste projeto, optou-se pela utilização conjunta de métodos clássicos de séries temporais e algoritmos clássicos de aprendizagem de máquina, assim, exploramos as vantagens de ambos os paradigmas: os métodos estatísticos fornecem baseline robusto e explicações teóricas sólidas, enquanto os métodos de ML permitem capturar relações não-lineares e interações mais complexas nas variáveis derivadas.

Essa combinação alinha-se com as práticas mais recomendadas na literatura recente, que reconhecem que modelos de machine learning podem complementar ou até superar os métodos estatísticos tradicionais, especialmente quando o problema é tratado como uma tarefa supervisionada por meio de boas práticas de feature engineering [4].

3. Objetivos

O objetivo principal deste projeto foi desenvolver e avaliar um sistema de previsão de séries temporais para estimar níveis de poluição do ar (material particulado – PM), comparando abordagens estatísticas clássicas e modelos de aprendizado de máquina.

Para atingir esse objetivo, o projeto buscou:

- Construir um pipeline completo de pré-processamento e engenharia de features a partir de séries temporais ambientais;
- Aplicar e comparar diferentes modelos de regressão e previsão temporal, incluindo métodos estatísticos e de machine learning;
- Otimizar os modelos por meio de busca em grade de hiperparâmetros (grid search);
- Empregar estratégias de validação adequadas a séries temporais, como TimeSeriesSplit e validação temporal progressiva;
- Selecionar e analisar o modelo final com base em métricas de erro (MAE e RMSE) e inspeção visual das previsões.

4. Equipamento e software utilizados

O desenvolvimento deste projeto foi realizado utilizando a linguagem Python 3, escolhida por sua ampla gama de bibliotecas voltadas para ciência de dados e aprendizado de máquina.

As principais bibliotecas empregadas foram:

- pandas: para manipulação e análise de dados;
- numpy: para operações numéricas e matrizes;
- scikit-learn xgboost: para a implementação de algoritmos de aprendizado de máquina e procedimentos de validação cruzada;
- statsmodels: para a modelagem estatística de séries temporais, incluindo o modelo SARIMAX;
- matplotlib e seaborn: para geração de gráficos e visualizações.

O ambiente de desenvolvimento utilizado foi o Google Colab e Jupyter Notebook, ferramentas que oferecem praticidade para projetos exploratórios e computação em nuvem. Quanto ao hardware, as análises foram realizadas utilizando CPU provida pela infraestrutura do Google Colab, sem a necessidade de aceleração por GPU.

5. Desenvolvimento

5.1 Coleta de dados

Os dados foram obtidos através da plataforma da Agência Europeia do Meio Ambiente, contendo medições diárias de material particulado (PM) em Lisboa, de 2018 a 2023. O poluente analisado foi o PM10 (Particulate Matter < 10 μm), partículas inaláveis com diâmetro inferior a 10 micrômetros, amplamente monitoradas devido ao seu impacto na saúde pública. De acordo com o dicionário do Dataset, este poluente é representado com o índice 5. Segundo a própria agência:

Este conjunto de dados ajuda a avaliar a exposição da população europeia a poluentes atmosféricos. Ele fornece uma visão geral da qualidade do ar com base em dados de estações oficiais de monitoramento (por meio de relatórios eletrônicos de qualidade do ar) nas cidades incluídas no projeto Auditoria Urbana [5].

O arquivo original foi obtido no formato Parquet, contendo 2.190 registros não nulos distribuídos em 11 colunas. Para o escopo deste projeto, foram selecionadas as seguintes colunas:

- 'Start': data correspondente à coleta da amostra;
- 'Value': valor medido da concentração de PM10 no ar.

Embora o poluente PM10 seja recomendado pela EEA a ser expresso em $\mu\text{g}/\text{m}^3$ (microgramas por metro cúbico), os valores do dataset foram disponibilizados em formato numérico muito pequeno (ordem de grandeza 0E-18).

5.2 Análise de dados

Foi realizada uma análise exploratória inicial com o objetivo de compreender a estrutura da série temporal, identificar tendências, verificar a presença de valores ausentes e possíveis anomalias.


O dataset foi dividido em conjunto de treino e conjunto de teste, utilizando 80% das observações para treino e reservando os 20% mais recentes (correspondentes ao último ano) para teste. Essa estratégia preserva a ordem temporal da série e evita vazamento de informações.

A partir da visualização gráfica da série temporal, associada ao cálculo de médias móveis e diferenciações, foi possível observar uma tendência ascendente a partir de 2021. Esse comportamento indicou mudanças relevantes na dinâmica da poluição medida.

Outro ponto importante observado foi a alta quantidade de valores iguais a zero, com 1.214 registros zerados no conjunto de treino, representando mais de 50% dos dados. Essa característica tem impacto direto na modelagem, podendo dificultar o aprendizado de padrões por parte dos algoritmos e prejudicar a capacidade de previsão. Essa questão foi considerada durante todo o desenvolvimento do projeto.

A imagem a seguir apresenta os principais indicadores estatísticos descritivos da variável-alvo ('Value'):

Figura 1 - Descrição estatística da coluna 'Value':



```
[ ] print(train['Value'].describe())
```

count	1826.000000
mean	5.748795
std	10.829517
min	0.000000
25%	0.000000
50%	0.000000
75%	10.575000
max	201.000000
Name: Value, dtype: float64	

Com base nesses achados, optou-se por não utilizar o ARIMA na abordagem inicial (baseline), priorizando o uso do SARIMAX — tanto com os dados originais quanto transformados por logaritmo e diferenciação. Essa escolha visou comparar o comportamento do modelo estatístico tradicional com abordagens de pré-processamento mais robustas, adequadas às características da série.

O ARIMA pressupõe uma série contínua e estacionária para obter bom desempenho. Entretanto, a quantidade expressiva de zeros (mais de 50% da série) compromete o ajuste do modelo, dificultando a captura dos padrões subjacentes. Além disso, o ARIMA tradicional é limitado à dependência univariada. Como o projeto previa a construção de variáveis derivadas (lags, estatísticas móveis, encoding temporal), foi mais apropriado adotar o SARIMAX, que permite a inclusão de variáveis exógenas e oferece maior capacidade de captura de informações relevantes da série.

5.3 Componentes da Série Temporal

O próximo passo foi identificar a presença de sazonalidades ou tendências cíclicas nos dados. Para isso, foram gerados gráficos agregados por semanas e meses, além de boxplots das distribuições por esses períodos temporais. Observou-se que os níveis de poluição tendiam a ser mais elevados durante os dias úteis, possivelmente devido ao aumento das atividades industriais e de transporte. Além disso, a partir do mês de abril, verificou-se um aumento gradual nos níveis de poluição.

Foi também realizado um teste com Análise de Componentes Principais (PCA), utilizando 60 defasagens como variáveis, com o objetivo de capturar possíveis padrões sazonais mais complexos. No entanto, os resultados não indicaram uma sazonalidade clara ou predominante na série.

Posteriormente, aplicou-se o método `seasonal_decompose()` para decompor a série temporal em seus componentes (tendência, sazonalidade e resíduo), utilizando a abordagem aditiva. A escolha do modelo aditivo foi necessária devido à elevada quantidade de valores iguais a zero na série, o que inviabilizaria o uso do modelo multiplicativo. A decomposição foi realizada tanto sobre os valores originais quanto sobre uma versão da série com outliers removidos, buscando identificar padrões de forma mais clara [6].

5.4 Baseline com SARIMAX

Como abordagem inicial, foi testado o modelo SARIMAX sobre a série original e sobre uma versão transformada da série, utilizando a transformação logarítmica ($\log_{1p}$) e diferenciação. Dado que a decomposição revelou uma tendência ascendente na série temporal, aplicou-se o teste de estacionariedade Augmented Dickey-Fuller (ADF) para confirmar se as transformações seriam suficientes para estabilizar a média da série.

Os resultados obtidos foram:

- Série original: ADF Statistic = -13.52 | p-value = 2.8×10^{-25} ;
- Série transformada ($\log_{1p}$ + diferenciação): ADF Statistic = -5.31 | p-value = 5.3×10^{-6}

Como o valor p em ambos os casos foi significativamente inferior a 0.05, rejeita-se a hipótese nula de não estacionariedade, indicando que as séries estavam estacionárias e adequadas para aplicação de modelos ARIMA/SARIMAX [7]. Portanto, considerou-se que as séries estavam adequadamente estacionárias para modelagem.

Na sequência, foi realizada uma busca pelos melhores hiperparâmetros de ordem (p, d, q), testando valores entre 1 e 4, tendo como critério de escolha a minimização do Akaike Information Criterion (AIC). Essa métrica penaliza a complexidade do modelo ao mesmo tempo em que avalia seu ajuste aos dados, permitindo selecionar o modelo com melhor desempenho. O menor AIC foi obtido com os parâmetros (3, 1, 3), onde:

- p (Auto-regressivo - AR): número de defasagens da série utilizada como input;
- d (Diferenciação): número de vezes que a série foi diferenciada para tornar-se estacionária;
- q (Média móvel - MA): número de defasagens do erro utilizado como input [7].

Os resultados do ajuste foram os seguintes:

- Série original: MAE = 9.08 | RMSE = 11.07 | AIC = 13556.93;
- Série transformada ($\log_{1p}$ + diferenciação): MAE = 1.21 | RMSE = 1.79 | AIC = 5749.54;

Apesar dos melhores resultados numéricos com a série transformada, a análise visual dos gráficos indicou que as previsões geradas eram excessivamente suavizadas e contínuas. Esse

comportamento está relacionado à natureza do SARIMAX, que busca prever valores médios, o que não reflete bem as flutuações abruptas e a grande quantidade de zeros presentes na série.

Em resumo, mesmo após aplicar as transformações apropriadas e obter estacionariedade, as características específicas da série temporal (muitos zeros e variações abruptas) limitaram o desempenho visual e interpretativo do SARIMAX, motivando a busca por abordagens complementares baseadas em aprendizado de máquina.

5.5 Modelos de Machine Learning com Feature Engineering e Param Grid

Baseado nas diretrizes do material do Lisbon Data Science Academy, construímos uma função para gerar atributos baseados na série temporal [8]. Foram geradas variáveis derivadas, incluindo lags, janelas móveis com agregações estatísticas e variáveis cíclicas baseadas no mês e no dia da semana e também indicações de feriados. Realizou-se uma busca em grade para diferentes combinações de parâmetros para os modelos de machine learning (regressão linear, random Forest e xgboost).

Para estes modelos, utilizamos os dados originais e com a transformação $\log_{1p}$, para poder comparar o desempenho dos modelos e também dos atributos em cada um dos cenários. Em relação ao desempenho dos modelos diante das diferentes combinações de atributos, utilizamos como métricas o erro Médio Absoluto (MAE) e a Raiz do Erro Quadrático Médio (RMSE).

O melhores modelos obtiveram as seguintes métricas e atributos, respetivamente:

- Com dados transformados: MAE: 0.595081 | RMSE: 0.826212;
- Com dados originais: MAE: 4.058627 | RMSE: 6.857948;
- Atributos: 'holidays': False | 'month': True | 'num_diffs': 0 | 'num_lags': 5 | 'rolling': ['mean', 'min', 'max', 'std'] | 'weekday': False};

O facto de a mesma combinação de atributos ter sido seleccionada nos dois cenários (transformado e original) é um bom indicativo de que essas features capturam bem as características relevantes da série. Considerando esse desempenho superior com $\log_{1p}$, decidimos utilizar apenas os dados transformados nas próximas etapas de modelagem.

Para fins de comparação, utilizamos exatamente os mesmos atributos como variáveis exógenas (exog) em um modelo SARIMAX. A inclusão dessas variáveis teve um impacto positivo no desempenho do modelo:

- MAE: 0.7725 | RMSE: 0.9373 | AIC: 4513.8214

5.6 Diferentes tipos de validações

Para garantir a robustez e a generalização do modelo escolhido, utilizou-se validação cruzada específica para séries temporais, por meio da classe `TimeSeriesSplit`, da biblioteca `scikit-learn`. Diferentemente da validação cruzada tradicional, que embaralha os dados aleatoriamente, a validação cruzada temporal respeita a ordem cronológica da série, simulando cenários reais de previsão futura a partir de dados passados.

Foi implementado um esquema de validação com 10 divisões sucessivas (`n_splits=10`), em que, a cada iteração, um novo bloco de dados mais recentes foi utilizado como conjunto de teste, enquanto os períodos anteriores serviram como treino. Essa abordagem permitiu avaliar a capacidade do modelo em se adaptar a mudanças ao longo do tempo.

O modelo empregado na validação foi a Regressão Linear, combinado com o conjunto de features obtido na busca em grade. Para cada divisão, foi calculado o Erro Médio Absoluto (MAE), e os resultados foram analisados tanto de forma individual quanto agregada.


Além da análise quantitativa, também foi realizada uma avaliação visual dos resíduos e das previsões em cada divisão, de forma a identificar eventuais padrões sistemáticos de erro. O MAE médio obtido ao longo das 10 divisões foi de 0.6748, confirmando a consistência do modelo na tarefa de previsão. Essa estratégia de validação foi fundamental para avaliar a estabilidade do modelo ao longo de diferentes períodos temporais e garantir que o desempenho não estivesse condicionado a um único recorte da série.

6. Resultados

6.1 Análise da decomposição sazonal

Com o objetivo de compreender melhor a estrutura interna da série temporal, foi realizada a decomposição dos dados utilizando o método `seasonal_decompose`, com abordagem aditiva. Foram analisadas duas versões da série:

Figura 2 - Gráficos da decomposição sazonal com dados originais (esquerda) e dados sem outliers (direita):



1. Dados Originais (à esquerda no gráfico):

- **Tendência (Trend):** A componente de tendência apresentou um comportamento relativamente claro, com uma queda acentuada entre 2018 e 2020, seguida de um crescimento gradual até 2022. Esse padrão coincide com o período pós-pandemia, quando houve retomada das atividades na cidade.
- **Sazonalidade (Seasonal):** A componente sazonal, porém, não evidenciou padrões periódicos muito claros, apresentando variações aparentemente aleatórias. Essa dificuldade de identificação pode estar associada à elevada quantidade de zeros e picos abruptos na série.
- **Resíduos (Resid):** O gráfico dos resíduos revelou a presença de pontos extremos (outliers), que contribuíram para ruídos significativos e dificultaram a modelagem puramente estatística.

2. Dados sem Outliers (à direita no gráfico):

- **Tendência (Trend):** Após a remoção dos outliers, a tendência tornou-se ainda mais clara e contínua, reforçando a percepção do crescimento gradual a partir de 2021.

- Sazonalidade (Seasonal): Mesmo sem os outliers, a componente sazonal ainda não revelou padrões cíclicos fortes. As flutuações continuam relativamente irregulares, sugerindo que o comportamento da série não é dominado por sazonalidade.
- Resíduos (Resid): Houve um aumento significativo na dispersão dos resíduos, o que é um indicativo de que o pré-processamento ajudou na estabilização da série.


A decomposição reforçou que a tendência é a característica dominante da série, enquanto a sazonalidade é fraca ou inexistente.

6.2 Baseline com SARIMAX

A partir dos testes realizados no desenvolvimento, observamos diferenças significativas entre os desempenhos do SARIMAX aplicado sobre a série original e sobre a série transformada. Em termos quantitativos, o modelo ajustado à série transformada (log1p + diferenciação) apresentou valores de MAE e RMSE substancialmente inferiores aos obtidos com a série original, como mencionados anteriormente.

Além da redução expressiva do erro e do AIC, a análise visual também evidenciou um contraste importante entre os dois cenários. No gráfico da série sem transformação, as previsões ficaram consistentemente na faixa dos 10, longe da maior parte dos valores observados na série temporal. Já no caso da série transformada, as previsões ficaram concentradas próximas a zero, alinhadas com a escala real dos dados.

Figura 3: Gráfico do desempenho do modelo SARIMAX com dados originais (esquerda) e dados transformados (direita):



Apesar disso, mesmo com as melhorias numéricas obtidas pela transformação log1p e pela diferenciação, foi possível notar que as previsões mantiveram um comportamento excessivamente suavizado e contínuo. Esse padrão visual limita a capacidade preditiva do modelo frente a variações

bruscas e a uma quantidade expressiva de valores zero na série — características que o SARIMAX, por sua natureza, tende a suavizar.


Portanto, ainda que o SARIMAX tenha mostrado ganhos em relação ao baseline não transformado, os resultados indicaram que seria necessário adotar abordagens alternativas para capturar melhor a complexidade da série. Essa constatação motivou o desenvolvimento posterior de modelos baseados em machine learning e a utilização de técnicas de engenharia de atributos, a fim de explorar mais profundamente os padrões da série e melhorar as previsões.

6.3 Modelos de aprendizagem de máquina

Os experimentos realizados com modelos de machine learning confirmaram o potencial das técnicas de engenharia de atributos para melhorar a capacidade preditiva da série temporal. Tanto os dados originais quanto os transformados ($\log_{1p}$) foram testados, o que possibilitou uma comparação direta entre os dois cenários.

Além dos resultados numéricos apresentados, a comparação visual entre as previsões do modelo SARIMAX puro (baseline) e o modelo de Regressão Linear com feature engineering reforça a superioridade desta abordagem.

Figura 4 - gráfico de desempenho dos modelos SARIMAX (esquerda) e Regressão Linear (direita) após a engenharia de atributos:



Na Figura do item anterior, observa-se que o SARIMAX ajustado diretamente sobre a série transformada gera previsões excessivamente suavizadas, incapazes de capturar as variações mais abruptas e as oscilações características da série temporal. Esse comportamento é esperado, dado que modelos da família ARIMA tendem a prever valores médios em séries com forte irregularidade. Já na Figura 4, que mostra as previsões dos modelos SARIMAX e Regressão Linear com as variáveis derivadas (lags, janelas móveis e componentes sazonais), percebe-se um ajuste muito mais aderente ao comportamento real da série, acompanhando melhor os picos e vales dos valores observados.

Essa diferença visual, alinhada aos resultados das métricas (redução expressiva de MAE e RMSE), confirma que o uso de aprendizado de máquina, aliado à engenharia de atributos, oferece um ajuste mais adequado e eficiente para séries temporais com comportamentos irregulares.

6.4 Validação cruzada e testes expansivos

Para garantir que o desempenho do modelo não fosse fruto de um ajuste específico a uma divisão particular dos dados, foi aplicada uma validação cruzada do tipo Time Series Split. Essa técnica respeita a ordem temporal da série, dividindo-a em múltiplos conjuntos de treino e teste de forma sequencial e expansiva, simulando cenários reais de previsão ao longo do tempo [8].


O procedimento foi realizado da seguinte forma:

- Utilizou-se o modelo LinearRegression, que apresentou o melhor desempenho nas etapas anteriores.
- As features utilizadas foram aquelas obtidas como mais eficazes na busca em grade (lags, janelas móveis estatísticas, etc.), aplicadas sobre a série transformada com $\log_{1p}$.
- Foi configurada uma validação cruzada com 10 divisões ($n_splits=10$).

Para cada divisão, o modelo foi treinado na parte inicial da série e testado no segmento seguinte. O desempenho de cada divisão foi avaliado com o Erro Médio Absoluto (MAE).

O gráfico gerado (Figura 5) exibe a evolução dos valores de MAE ao longo dos diferentes períodos de teste. Cada ponto representa o MAE obtido em uma divisão específica da validação cruzada, associado à data de início daquele período de teste.

Figura 5 - gráfico do MAE por divisão temporal:



Observa-se que:

- Nos primeiros períodos, os erros são baixos e estáveis, indicando boa capacidade do modelo de capturar o comportamento da série naquele intervalo.

- A partir da sexta divisão, há um aumento progressivo nos valores de MAE. Esse comportamento é esperado, pois as divisões posteriores abrangem períodos mais recentes e desconhecidos para o modelo, tornando as previsões mais desafiadoras.
- Mesmo com esse aumento, os valores permanecem dentro de um intervalo aceitável, sem indicar falhas graves de generalização.

O MAE médio ao longo das 10 divisões foi de aproximadamente 0.6758, confirmando um desempenho consistente do modelo mesmo sob cenários simulados de previsão futura.

Esse tipo de validação é fundamental para testar a robustez temporal do modelo, assegurando que ele não esteja apenas memorizando padrões passados, mas conseguindo generalizar para dados futuros.

7. Discussão

Um dos principais pontos deste trabalho foi a aplicação de técnicas específicas de engenharia de atributos (feature engineering), que desempenharam um papel fundamental na melhoria do desempenho preditivo, tanto dos algoritmos de aprendizado de máquina quanto do modelo estatístico SARIMAX.

Para os algoritmos de machine learning supervisionado, como a Regressão Linear, a introdução de variáveis defasadas (lags), estatísticas móveis e codificações temporais transformou a tarefa de previsão de séries temporais em um problema clássico de regressão. Essa abordagem permitiu que esses modelos, originalmente não projetados para capturar dependências temporais, passassem a identificar padrões relevantes ao longo do tempo, resultando em uma redução consistente dos erros de previsão.

Além disso, a utilização dessas mesmas variáveis derivadas como variáveis exógenas no modelo SARIMAX proporcionou ganhos importantes em relação ao modelo univariado tradicional. Enquanto o SARIMAX já era capaz de capturar autocorrelações e padrões sazonais, a inclusão de atributos como médias e desvios padrão móveis ampliou sua capacidade de antecipar variações de curto prazo na série.

Esses ganhos estão diretamente relacionados às características específicas da série temporal analisada, marcada por um número expressivo de zeros e por variações irregulares. Tais propriedades dificultam o trabalho de modelos puramente estatísticos, pois estes tendem a assumir estruturas mais lineares ou padrões estáveis de autocorrelação. Nesse contexto, o feature engineering atuou como um mecanismo essencial para expor ao modelo sinais ocultos e regularidades locais.

Esse resultado evidencia a sinergia entre abordagens estatísticas clássicas e técnicas modernas de machine learning, reforçando a importância de um bom projeto de features em problemas de previsão temporal. Observou-se, inclusive, que o desempenho final dos modelos foi mais influenciado pela qualidade das variáveis utilizadas do que necessariamente pela escolha do algoritmo, confirmando o papel decisivo da engenharia de atributos em tarefas deste tipo.

8. Conclusão

O projeto alcançou com sucesso o objetivo de implementar um comportamento inteligente voltado para previsão de séries temporais de poluição do ar. A partir da comparação entre diferentes métodos, identificou-se que a abordagem mais simples (Regressão Linear com defasagens) foi a mais eficaz, equilibrando precisão, simplicidade e interpretabilidade.

Perspectivas futuras incluem:

- Testes com modelos mais sofisticados, como redes neurais recorrentes (RNN, LSTM);
- Inclusão de variáveis externas (exógenas), como clima ou feriados;
- Aplicação em séries temporais de diferentes poluentes ou regiões.

9. Referências e Bibliografia

- [1] Hyndman, R.J., & Athanasopoulos, G. (2018). Forecasting: principles and practice. OTexts. <https://otexts.com/fpp3/>. Acesso em 13/06/2025.
- [2] Bontempi, G., Taieb, S. B., & Le Borgne, Y. A. (2013). Machine Learning Strategies for Time Series Forecasting. In European Business Intelligence Summer School. https://link.springer.com/chapter/10.1007/978-3-642-36318-4_3. Acesso em 13/06/2025.
- [3] Montero-Manso, P., & Hyndman, R. J. (2021). Principles and Algorithms for Forecasting Groups of Time Series: Locality and Globality. International Journal of Forecasting, 37(4), 1632-1653. <https://arxiv.org/abs/2008.00444>. Acesso em 13/06/2025.
- [4] Lim, B., Arik, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting. International Journal of Forecasting, 37(4), 1748-1764. <https://arxiv.org/abs/1912.09363>. Acesso em 13/06/2025.
- [5] EEA DMZ Downloads. Disponível em: <https://eeadmz1-downloads-webapp.azurewebsites.net/>. Acesso em: 16 jun. 2025.
- [6] Lisbon Data Science Academy (LDSSA). Learning notebook - Part 1 of 3 - Time series components. Disponível em: <https://github.com/LDSSA/batch7-students/blob/main/S03%20-%20Time%20Series/BLU05%20-%20Classical%20Time%20Series%20Models/Learning%20notebook%20-%20Part%201%20of%203%20-%2020Time%20series%20components.ipynb>. Acesso em: 16 jun. 2025.
- [7] Lisbon Data Science Academy (LDSSA). Learning Notebook - Part 2 of 3 - SARIMAX. Disponível em: <https://github.com/LDSSA/batch7-students/blob/main/S03%20-%20Time%20Series/BLU05%20-%20Classical%20Time%20Series%20Models/Learning%20notebook%20-%20Part%202%20of%203%20-%2020SARIMAX.ipynb>. Acesso em: 16 jun. 2025.
- [8] Lisbon Data Science Academy (LDSSA). Learning Notebook - Part 2 of 3 - Time Series Pre-processing and Feature Engineering. Disponível em: <https://github.com/LDSSA/batch7-students/blob/main/S03%20-%20Time%20Series/BLU06%20-%20Machine%20Learning%20for%20Time%20Series/Learning%20notebook%20-%20Part%202%20of%203%20-%2020Time%20series%20pre-processing%20and%20feature%20engineering.ipynb>. Acesso em: 16 jun. 2025.
- [9] Lisbon Data Science Academy (LDSSA). Learning Notebook - Part 3 of 3 - Advanced topics on ML for Time Series Forecasting. Disponível em: <https://github.com/LDSSA/batch7-students/blob/main/S03%20-%20Time%20Series/BLU06%20-%20Machine%20Learning%20for%20Time%20Series/Learning%20notebook%20-%20Part%203%20of%203>

[3%20-%20Advanced%20topics%20on%20ML%20for%20time%20series%20forecasting.ipynb](#). Acesso em: 16 jun. 2025.